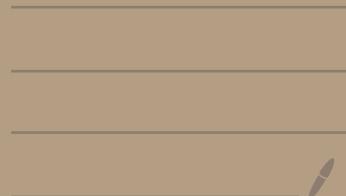


ベイズ推論

Chapter 1 (前半)



この本、位置付け。

・ベイズ主義機械学習（ベイズ学習）に基づいた、実践的な
データ解析アルゴリズムの構築法に関する解説本。

～ 目的や状況に合わせて自由にアルゴリズムを作りこなす
が目標。

Notation

確率分布

- \mathcal{N} : ガウス分布
- Bern : ベルヌーイ分布
- Bin : ニュートン分布
- Cat : カテゴリ分布
- Mult : 多項分布
- Poi : ポアソン分布
- Beta : ベータ分布
- Dir : ディリクレ分布
- Gam : ガンマ分布
- W : ウィニアード分布

1. 機械学習とベイズ学習

1.1. 機械学習とは

根本における機械学習、トイキ。

1.1.1. 機械学習

... データに潜む規則や構造を抽出する事によう。
未知の現象に対する予測や規則に基づく判断を行
うための計算技術の総称。

1.2. 機械学習の代表的なタスク

① 各タスクはベイズ推論による $L - \text{G} - \text{G}$ の形式的 ($L \cap G \cap G$) で表す。

1.2.1. 回帰

回帰 (regression)

- 表す元の元の入力 $x \in \mathbb{R}^m$ から連続値の出力 $y \in \mathbb{R}$ を予測する
ための関数 $y = f(x)$ をデータから求めること。

線形回帰

$$X = \{x_1, \dots, x_N\} : \text{入力データ}$$

$$Y = \{y_1, \dots, y_N\} : \text{入力データに対する実際の出力データ}.$$


$$w \in \mathbb{R}^m : \text{係数ベクトル}.$$

$$y_n = w^T x_n + \varepsilon_n \quad (1.1)$$

確率的生成
モデル。

目標

手元にあるデータ X や Y を使い、各変数 x と y の関係をうまく捉えられるように w を求めよ。



• $M = 1$ のとき、直線。

$$y = \omega x$$

~ 手元に x^1, x^2, \dots, x^n を持てば、直線で予測可能。
新規の入力点 x^* が与えられたときに、未知の ω や y^* を予測できる。

• $M = 3$ のとき。

$$\begin{cases} (\omega_1, \omega_2, \omega_3)^T : 1^{\text{次}} \text{ 多項式} \\ (1, x, x^2)^T : \text{入力変数} \end{cases}$$

$$\Rightarrow y_n = \omega_1 + \omega_2 x_n + \omega_3 x_n^2 + \varepsilon_n \quad (1.2)$$

上、2つ目は 多次式回帰 (polynomial regression)

~ 元の観測データを解析することでいう意味で 特徴量抽出
(feature extraction)

1.2.2. 分類

出力値 y が有限個の二値に限定。

$$\text{例}: y_n \in \{0, 1\}$$

$$m_n \in (0, 1) : y_n = 1 \text{ の確率}.$$

$x_n \in \mathbb{R}^m$, $\omega \in \mathbb{R}^m$ とする m_n を表現するモデル。

$$m_n = f(\omega^T x_n) \quad (1.3)$$

f には シグモイド関数 (sigmoid function) がよく使われる。

$$f(a) = \text{Sigmoid} : = \frac{1}{1 + e^{-a}} \quad (1.4)$$

• $\omega^T x$ の値 (= 総和)
 $m_n \in (0, 1) \approx 73\%$

① 実際の観測が $y_n = 0$ のときは、 $y_n = 1$ の確率が 0 以下
 $m_n < 0.5$ の値 (決して) 確率的でない。

目標

与えられたデータセット X 、 y から $1^{\text{次}} \text{ 多項式 } \omega$ を学習し、新規の入力 x^* に対する
未知の出力値 y^* を確率的に予測する。

前述の考え方には、複数クラスの分類に対しても簡単に拡張できる。

K個のクラスに対する分類器

・Yトマト、クラス内似合 (softmax function)

$$f_k(a) \approx S M_k(a) := \frac{e^{a_k}}{\sum_{k'=1}^K e^{a_{k'}}} \quad (1.5)$$

を使うこととする。

1.2.3. クラスタリング


・クラスタリング (clustering)

与えられたN個のデータ $X = \{x_1, \dots, x_n\}$ を基準に従って、K個の集合(=クラス)に分ける。

例) ガウス混合モデル (Gaussian mixture model)

すべてのデータ x は対して、クラスタ所属の推定値 $\hat{\pi} = \{\hat{\pi}_1, \dots, \hat{\pi}_n\}$ が割り当てられる。

… クラス k , 平均 M_k , 共分散行列 Σ_k を守る。



- 推定された $\hat{\pi}$ を用いて、单纯化して分類。可視化
- 複数の異なる傾向をもつようなデータをモテリ化

1.2.4. 次元削減

・線形次元削減 (Linear dimensionality reduction)

データ $X \in \mathbb{R}^{D \times N}$ が $W \in \mathbb{R}^{M \times D}$ によって $Y \in \mathbb{R}^{M \times N}$ とされる。

通常 $M < D < N$

$$Y \approx W^T X \quad (1.6)$$

$$\begin{matrix} D \\ \boxed{Y} \end{matrix} \underset{\sim}{\approx} \begin{matrix} M \\ W^T D \end{matrix} \begin{matrix} N \\ X \end{matrix}^m$$

→十分大きな N に対して、データ数が DN から $MD + MN$ に圧縮できる。

例) $D = 100, N = 1000, M = 10$

$$\rightarrow DN = 100000, DM + MN = 11000 \quad (\text{圧縮})$$

一般に $w^T x$ は元で τ で y を完全には復元できないが、
 y に存在する特徴的な情報をうまく保持するよう w を τ に沿って
設定される。
… y と $w^T x$ の誤差を最小基準で扱うが、最もには $\|w\|^2$
 w, x を決める。

② 次元削減後、 x は τ に含まれるノイズを排除して本質的な
情報を保持していくと考えることができる
… x を他の分類アルゴリズムに入力して使いこなす。実践では
上に行われる。

行は y の分子の番目、列は主目可と。

$y \approx w^T x$ (1.7)
… 本質的には線形回帰 (1.1) と同じ。
… 各列は τ から独立。

1.2.5. その他、代表的な τ 々々。

- ・ 与えられた信号の系列で前記 τ デルタに基づく分離。
… 音声信号分離。
- ・ 不規則な補助。
… ECサイトにおける商品、(この $x = \tau - \text{ショーン}$)
… 一般的なログデータの解析。

生成モデル (generative model)

- … モデルが生成過程を直書きにしてしまう。
人工的な τ でシミュレーションが可能。

1.3. 機械学習, 279 770Q-7.

1.3.1. ニューラルネットワークによる機械学習。
ニューラルネットワークによる770Q-7

…既存, または新しい予測アルゴリズムに適用して770Q-7。

770Q-7から何とか, 基準に基づく性能を包みアルゴリズムを評価していく。
最終的な予測や判断を行なう。

2.1. 最近傍法 (nearest neighbor)

…2局で770Q-7は最も近い入力データを検索し, 770Q-7は対応する
ラベル(出力値)を予測結果とする。

サポートベクターマシン (support vector machine)

ブースティング (boosting)


ランダムフォレスト (random forest)

3) 教師あり学習 (supervised learning)

入力データと出力データ(正解ラベル)のペアを訓練データとして
予測モデルを教習する。

① アルゴリズムが特定の分野やデータに対して学習する
すべての特徴量を学習する。

～特徴量抽出 (feature extraction) と呼ばれる770Q-7
を前段階に置くことで、個々の入力は複数機能向上を目指す。



特徴量抽出の役割

変換 (多角形変換, ハミング変換), 2次元削減

ア70Q-子9点

- ・高度な数学の知識がなくても、アラビア数字や技術が出来れば機械学習システムを構築できます。
… 最近はライブラリで提供。
- ・比較的簡単なデータセットを行って、所望の結果が得られるのが多い

ア70Q-子9点

- ・使いたいには必ず構架思想を持ち、アラビア数字や技術を理解しておかなければなりません。
- ・精度や適用度も子供より範囲が広くなりました。

1. 3. 2. モデリゼーションと機械学習

モデリゼーションと機械学習

- … テーマ(角)のモデル(仮説)を事前に構築。
～ モデル(角)からデータや構造をデータから学習するまで、何かしらの有益な予測や判断を行います。

⑥ 対象となる、どのような課題に対する仮定・制約でありますか？ 計算過程に記述。

→ 推論や最適化などの計算的な手法に基づいてデータを構成し、構成特徴を抽出します。

トピックモデル (topic model) … 自然言語処理

- ・文章が複数の潜在的な（観測できない）トピックやテーマを持つ、どのような仮定。
- トピックに応じて文章中の個々の言語が出現していくことをモデル化。

時系列モデル (time series model)

状態空間モデル (state space model)

e.g. 隠れマーカルモデル (hidden Markov model, HMM)

… データ、離散的な変化をモデル化。

線形動的システム (linear dynamical system)

… 状態の連続的な変化をモデル化。

カルマンフィルタ (Kalman filter) … 推論アルゴリズム

確率的ブロックモデル (Stochastic block model)

…つながりの強度を確率的に予測するためのモデル。


深層学習 (deep learning)

…一部の人間、脳における階層的な情報処理を部分的にモデル化。
～画像認識や音声認識のタスクで高い精度。

① モデル構造アーキテクチャも、とても注目される点は、

解釈性から、内訳や構成について考慮されることが多い

数理的モデルを用いて、CFM組み合せによって「モデル」(= フォーマット)としている。



特徴

主な特徴は、PILによる画像の読み込み。

} モデル構築
X
} 予測論計算

これが明確にどのように分けられる。

アーキテクチャの特徴

- ・ツールボットによるアーキテクチャと比べて精度と柔軟性が高くなる傾向がある。
- タスクごとにモデルのアーキテクチャが異なる。
- データの仮定を数理的に明記することで、何通りのタスクが自然に解けるか、他のモデルや種類のモデルがどのデータを統合できる。
- ・隣接の対象となるミステリに対する確実性をうまく表現できる。
- ・特性が低い和をもつ確率分布を「ロジスティック関数」と呼ぶ。多くの課題に適した手法を一貫性をもつ提携できる。

77% - 79% 計算

- ある程度、秋葉の知識をもつ子。
- 計算時間で × 多いことをかかず。

1.4. 確率的基本計算

1.4.1. 確率分布

Def (確率密度函数)

Let $\mathbf{x} = (x_1, \dots, x_m)^\top \in \mathbb{R}^m$: 密度値
 $p(\mathbf{x})$ is a p.d.f.

$$\Leftrightarrow p(\mathbf{x}) \geq 0$$

$$\int p(\mathbf{x}) d\mathbf{x} = \int \dots \int p(x_1, \dots, x_m) dx_1 \dots dx_m = 1 \quad (1.8)$$

例): $M = 1$ の Gaussian distribution (= 277) の p.d.f.

$x \in \mathbb{R}$,

$\mu \in \mathbb{R}$: 平均, $\sigma^2 \in \mathbb{R}^+$: 分散.

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (1.10)$$

Def (確率 (質量) 密度)

Let $\mathbf{x} = (x_1, \dots, x_m)^\top$: 質量

$p(\mathbf{x})$ is a p.m.f.

$$\Leftrightarrow p(\mathbf{x}) \geq 0$$

(1.11)

$$\sum_{\mathbf{x}} p(\mathbf{x}) = \sum_{x_1} \dots \sum_{x_m} p(x_1, \dots, x_m) = 1, \quad (1.12)$$

例): ベルヌーイ分布

$x \in \{0, 1\}$, $\mu \in (0, 1)$

$$p(x) = \mu^x (1-\mu)^{1-x} \quad (1.13)$$

$$\begin{cases} x=1 : コイニ 9 素が出了 \\ x=0 : コイニ 9 素が出了 \end{cases} \quad \text{確率} = p_3.$$

$$P(x=1) = \frac{1}{M} \quad (1.14)$$

$$P(x=0) = \frac{1}{M} \quad (1.15)$$

M : コイニ 9 素が出了確率。

この本で扱う範囲におけるは、p.d.f. や p.m.f. でタイキする分布を **確率分布** と呼ぶ。これは p_3 。

次回、一般的な議論を行な際に必ず積分表記を用い。

1.4.2. 確率分布の推論。

同時分布 (joint distribution) $p(x, y)$
ある 2つの変数 $x \times y$ に対する確率分布

周辺化 (marginalization)

$$p(y) = \int p(x, y) dx \quad (1.16)$$

一方の変数 x を積分により除去する操作。
 $p(y)$ を周辺分布 (marginal distribution) という。

条件付き分布 (conditional distribution)

$$p(x|y) = \frac{p(x, y)}{p(y)} \quad (1.17)$$

y に対する特定の値が決まると x の確率分布。
 $p(x|y)$ は x の確率分布
… y が一定の分布を持つと決まる（独立性）。

(1.16), (1.17) より、

$$\int p(x|y) dx = \frac{\int p(x, y) dx}{p(y)} = \frac{p(y)}{p(y)} = 1. \quad (1.18)$$

$p(x, y) \geq 0$, $p(y) \geq 0$ すなはち、条件付分布 $p(x|y)$ は (1.8), (1.9)

であることを示す。この条件付分布も同様 (2)。

$$p(y|x) = \frac{p(x,y)}{p(x)} \quad (1.19)$$

Th (ベイズの定理)

$$\frac{p(x|y)}{\int p(x|y) dx} = \frac{p(y|x)p(x)}{\int p(x,y) dx} \quad (1.20)$$

結果 y の得られる
原因 x の確率

原因 x から結果 y が
得られる確率。

④ ベイズの定理は、時間順行、確率が時間逆行の確率
を計算するといつてもよい。

独立性 (independence)

$$p(x,y) = p(x)p(y) \quad (1.21)$$

もし x と y は独立であるといふ。

$$\frac{p(x,y)}{p(y)} = p(x) \quad \therefore p(x|y) \approx p(x) \quad (1.22)$$



($\because (1.21)$) y が条件で与えても
 x の確率分布は変わらない。

⑤ 確率推論に基づく機械学習の方法論は、周辺化。
条件付分布の計算 (x がベース)

ベイズ的推論 (Bayesian inference/reasoning)
(確率)的推論 (inference)

- ある同時分布が与えられたとき、そこから興味のある量を
条件付分布や周辺分布を算出する。

1.4.3. 赤玉白玉肉題



② 完全にアーティクルな確率 ($1/2$ ずつ)
で袋からまたぬいもの八百半から選ぶ、
選んで袋の玉を(?)ずつ取り出す
行為を考え方。

$x = a$: 袋 a が選ばれた? 布団。
 $x = b$: 袋 b =

$$\begin{array}{lcl} P(x=a) & = & \frac{1}{2} \\ P(x=b) & = & \frac{1}{2} \end{array} \quad \begin{array}{l} (1, 23) \\ (1, 24) \end{array}$$

$\gamma = r$: 取り出しが玉が赤
 $\gamma = w$ $\hat{\gamma}$ 白

$$\begin{aligned} P(Y=r \mid X=a) &= \frac{2}{3}, & (1.25) \\ P(Y=\omega \mid X=a) &= \frac{1}{3}, & (1.26) \\ P(Y=r \mid X=b) &= \frac{1}{4}, & (1.27) \\ P(Y=\omega \mid X=b) &= \frac{3}{4}. & (1.28) \end{aligned}$$

(1.23) ~ (1.28) & 用以 3 x.

ପ୍ରକାଶକ

$$\begin{cases} p(x=a, y=r) : \text{選ばれた袋が A で、赤玉が出た確率} \\ p(x=b, y=r) : \quad = \quad b \quad = \end{cases}$$

$$P(X=a, Y=r) = P(Y=r | X=a) P(X=a)$$

$$= \frac{2}{3} \cdot \frac{1}{2} = \frac{1}{3} \quad (1, 29)$$

$$\begin{aligned} p(x=b, y=r) &= p(y=r | x=b) \cdot p(x=b) \\ &= \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{8} \quad (1.30) \end{aligned}$$

「選ばれた袋(2) 内で r 取り出された玉が赤玉である」の確率
 ~) 周辺確率 $p(x=r)$ (2 答え)

$$\begin{aligned} p(y=r) &= \sum_x p(x, y=r) \\ &= p(x=a, y=r) + p(x=b, y=r) \quad (1.31) \\ &= \frac{1}{3} + \frac{1}{8} = \frac{11}{24} \quad (1.32) \end{aligned}$$

「取り出された玉が赤で無いことを加へると、P2 の場合(2) 選ばれた袋
 が a で無い確率」の確率
 ~) $p(x=a | y=r)$

$$\begin{aligned} p(x=a | y=r) &= \frac{p(x=a, y=r)}{p(y=r)} \quad (1.33) \\ &= \frac{\frac{1}{3}}{\frac{11}{24}} = \frac{8}{11} \quad (1.34) \end{aligned}$$

同じ条件下で、選ばれた袋が b で無い場合を考える。

$$\begin{aligned} \sum_x p(x | y=r) &= p(x=a | y=r) + p(x=b | y=r) \\ &= 1 \quad (1.35) \end{aligned}$$

より,
 $p(x=b | y=r) = 1 - p(x=a | y=r) = \frac{3}{11} \quad (1.36)$

事後分布 (posterior)

データが観測された後の分布
 (1.34), (1.36)

事前分布 (prior)

データを観測する前の分布
 (1.23), (1.24)

1.4.4. 食間で「 γ 」が複数個ある場合、
1.4.3.9 内部を発展させた内部を考える。

ある町内会で、袋 a, b を使ったくじ引き大会が開かれる場合、

Setting

1. 主催者はどうするか袋を今回くじ引き大会に用ひ子供と等しくして事前に選ぶ、どうぞを選んでからは参加者12名にせぬ。

2. 参加者は選ばれた袋から玉を取り出し、それを確認して元の袋に戻す（復元抽出）

3人、参加者がくじ引きをした結果を得て、

$$\{Y_1, Y_2, Y_3\} = \{r, r, w\} \quad (1.37)$$

ここで、主催者は、1選ばれた袋が a, b のどちらかを知る確率ははうずめはよいか。

≈ 27.9 確率を復元する内部 (2.2.3).

$$P(X | Y_1 = r, Y_2 = r, Y_3 = w) \quad (1.38)$$

ここで、復元抽出の仮定か？

$$\begin{aligned} P(Y_1 = r, Y_2 = r, Y_3 = w | X) \\ = P(Y_1 = r | X) P(Y_2 = r | X) P(Y_3 = w | X) \end{aligned} \quad (1.39)$$

…袋がすでに選ばれていた状態において、はがき参加者と川崎、すでに取り出された結果とは無関係。

ベイズの定理と (1.39) 並べる。

$$\begin{aligned} P(X | Y_1 = r, Y_2 = r, Y_3 = w) \\ = \frac{P(Y_1 = r, Y_2 = r, Y_3 = w | X) P(X)}{P(Y_1 = r, Y_2 = r, Y_3 = w)} \\ = \frac{P(Y_1 = r | X) P(Y_2 = r | X) P(Y_3 = w | X) P(X)}{P(Y_1 = r, Y_2 = r, Y_3 = w)} \end{aligned} \quad (1.40)$$

(1.40) 式) .

$$P(x | \gamma_1 = r, \gamma_2 = r, \gamma_3 = \omega) \\ \propto P(\gamma_1 = r | x) P(\gamma_2 = r | x) P(\gamma_3 = \omega | x) p(x) \quad (1.41)$$

式) .

$$P(x = a | \gamma_1 = r, \gamma_2 = r, \gamma_3 = \omega)$$

$$\propto P(\gamma_1 = r | x = a) P(\gamma_2 = r | x = a) P(\gamma_3 = \omega | x = a) p(x = a) \\ = \frac{2}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{1}{2} = \frac{2}{27} \quad (1.42)$$

式) .

$$P(x = b | \gamma_1 = r, \gamma_2 = r, \gamma_3 = \omega)$$

$$\propto P(\gamma_1 = r | x = b) P(\gamma_2 = r | x = b) P(\gamma_3 = \omega | x = b) p(x = b) \\ = \frac{1}{4} \cdot \frac{1}{4} \cdot \frac{3}{4} \cdot \frac{1}{2} = \frac{3}{128} \quad (1.43)$$

式) . $\sum_x P(x | \gamma_1 = r, \gamma_2 = r, \gamma_3 = \omega) = 1$ 式) .

$$P(x = a | \gamma_1 = r, \gamma_2 = r, \gamma_3 = \omega) = \frac{\frac{2}{27}}{\frac{2}{27} + \frac{3}{128}} = \frac{256}{337} \quad (1.44)$$

$$P(x = b | \gamma_1 = r, \gamma_2 = r, \gamma_3 = \omega) = \frac{\frac{3}{128}}{\frac{2}{27} + \frac{3}{128}} = \frac{81}{337} \quad (1.45)$$

上記計算で用いた.

分子分母の計算がなぜ正確化するか
よく理解できないことはある.

二二九式) は観測価が得られたとき.

$$(1.46) \{ \gamma_1, \dots, \gamma_8 \} = \{ r, r, \omega, \omega, r, r, \omega, r \} \quad (1.46)$$

$$\Rightarrow P(x = a | \gamma_1, \dots, \gamma_8) = 0.9221 \dots \quad (1.47)$$

$$(1.48) 50回の式) で赤玉21個、白玉21個$$

$$\Rightarrow P(x = a | \gamma_1, \dots, \gamma_{50}) = 0.9999 \dots \quad (1.48)$$

① なぜ多くの式) で観測価が未だ9個を取るか?

1. 4. 5. 逐次推論

逐次推論 (sequential inference)

・複数の独立なデータから成り立つ重要な特徴.

1個の観測値 y_1 が得られたとき.

事後分布は,

$$p(x|y_1) \propto p(y_1|x) p(x) \quad (1.49)$$

… 事前分布 $p(x)$ が $\dots - y_1$ を観測したとき $p(x|y_1)$ に更新された.

$\dots - y_1$ 加え 2個 $\{y_1, y_2\}$ 得られた場合.

$$\begin{aligned} p(x|y_1, y_2) &\propto p(y_1, y_2|x) p(x) \\ &\propto p(y_2|x) p(y_1|x) p(x) \\ &\propto p(y_2|x) p(x|y_1) \end{aligned} \quad (1.50)$$

… $\dots - y_1$ を 1個観測した後分布 $p(x|y_1)$ が、 $\dots - y_1 y_2$ を観測したとき $(2点)$ 、事後分布 $p(x|y_1, y_2)$ に更新された.

一般に、観測値 $Y = \{y_1, \dots, y_N\}$ の確率密度 (x が満たす条件で) 独立で取った場合、同時分布は、

$$p(x, Y) = p(x) \prod_{n=1}^N p(y_n|x) \quad (1.51)$$

となる.

∴ 同じように、 $\dots - y_1$ を受け取ったときの事後分布は.

$$\begin{aligned} p(x|Y) &\propto p(x) \prod_{n=1}^N p(y_n|x) \\ &\propto p(y_N|x) \underbrace{p(x|y_1, \dots, y_{N-1})}_{N-1個の \dots - y_1 を使った事後分布} \end{aligned} \quad (1.52)$$

N-1個の $\dots - y_1$ を使った事後分布.

逐次学習 (sequential learning), 追加学習 (incremental learning),
 オンライン学習 (online learning)
 ・以前に得られた事後分布を次の推論のための事前分布として使
 ような学習方法
 (逐次的) 更新手法 (逐次更新手続)

1. 4. 6. $(\theta_{\text{ラメータ}})$ が未知である場合
 1. 4. 3, 1. 4. 4, 肉類は現実肉類とてはシニ $\theta_{\text{ラメータ}}$ る,
 13]: これらの主催者が本当に $\frac{1}{2}$ の確率で袋を選択する
 倍率で玉は一見全
 - 玉の出現率
 - 玉の色
 :

~ 特に、玉が取り出される比率 θ ($\theta_{\text{ラメータ}}$ が未知) であり、
 (いくつか玉を取り出すまで θ の $(\theta_{\text{ラメータ}})$ (肉の確率) を
 行なつて可る。

Setting

赤玉と白玉が複数個入った袋があり、そこから
 玉を取り出し色を確認するという形式で N 回繰り返す。

目標

赤玉と白玉の未知の比率 $\theta \in (0, 1)$ は肉の
 確率分布 $p(\theta)$ を考えることとする。確率的推論にて
 を用いてデータから θ に肉の知見を得ること。

$$Y = \{Y_1, \dots, Y_N\} : \text{観測} \rightarrow \cdot$$

二、問題を具体的な同時分布と(7)記述.

$$p(\gamma, \theta) = p(\gamma|\theta) p(\theta) = \left(\prod_{n=1}^N p(\gamma_n|\theta) \right) \underline{p(\theta)} \quad (1.53)$$

各データ点が
θの値で決まる
確率分布によること。
(1.7x-9)は内々
事前分布。
θがどうしたくても
何らか事前知識を
反映。

③ 1.7x-9は内々事前知識を具体的に計算する方法について、

1. ベーチ分布 (Beta distribution)
 2. ディリクレ分布 (Dirichlet distribution)
- を利用することとする。

目的

θのどうなる値を、データのYを観測するほど、θを推論する。
~) $p(\theta|Y) \propto p(Y|\theta) p(\theta) \quad (1.54)$

を計算する。

○ $p(\theta|Y)$: 1.7x-9の事後分布,
データYの観測を通じて事前知識 $p(\theta)$ が更新。

ベイズ推論を用いる不確実性である。

未知の値θに対する、何かしら確率論的な仮説 $p(\theta)$ を事前に持つ。
「データYを観測するほどで、仮説を更新する」
これが主張されるべきで、直接観測できない現象を明示する。