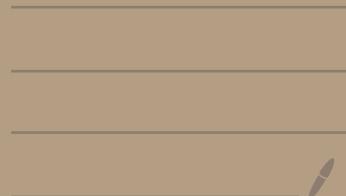


# ベイズ推論

---

Chapter 3 (3.1, 3.2)



### 3. ベイズ推論による学習と予測

・  $p(\theta | x)$ , 事後分布および未観測値の予測分布, 解析的な計算.

#### 3.1. 学習と予測

① 確率推論を用いた  $p(\theta | x)$  の学習と未観測値の予測.

#### 学習 (training, learning)

モデルもつづく  $\theta$  の値をデータから決定することで.

…ベイズ推論では、 $p(\theta | x)$  を確率変数として扱う.

～) 確率計算によ、データを観測した後、事後分布を求めることが学習にあたり.

予測も行う.

##### 3.1.1. $p(\theta | x)$ の事後分布.

$D$ : 訓練データ集合.

$$p(D, \theta) = p(D|\theta)p(\theta) \quad (3.1)$$

$\theta$ : モデルに含まれる未知パラメータ.

$p(\theta)$ :  $p(\theta | x)$  の事前分布.

$p(D|\theta)$ : 大度内积

… 特定の  $p(\theta | x)$  よりよくしてデータ  $D$  が発生するかを記述.

② ベイズの定理を用いた  $p(\theta | x)$  の不確実性, 更新.

$$\underline{p(\theta | D)} = \frac{\underline{p(D|\theta)p(\theta)}}{p(D)} \quad (3.2)$$

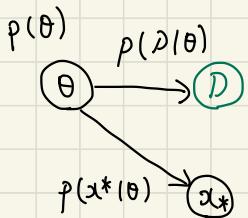
～) 条件付分布  $p(\theta | D)$  を計算することが、ベイズ学習における「学習」(2段階).

大度内积を用いてより観測データ  $D$  の確実性を扱ってみることで加算的.

### 3.1.2. 予測分布

$$P(x_* | D) = \int p(x_* | \theta) \underbrace{p(\theta | D)}_{\text{重み}} d\theta \quad (3.3)$$

手元でこれを計算する。



- Dも  $x_*$  も  $\pi^0$  で  $x - \bar{x}$  の間による、 $\pi^0$  が支配的
- $D \sim x_*$  で、直線的な依存関係は仮定する。  
→  $\pi^0$  が与えられたときに条件付独立。

対応する同時分布は、

$$p(D, x_*, \theta) = p(D|\theta) p(x_*|\theta) p(\theta) \quad (3.4)$$

→  $D$  に対する手元の式をとる。  
これが事後分布。

$$\begin{aligned}
 p(x_*, \theta | D) &= \frac{p(D, x_*, \theta)}{p(D)} \quad (\because \text{ Bayes })
 \\
 &= \frac{p(D|\theta) p(x_*|\theta) p(\theta)}{p(D)} \quad (\because (3.4))
 \\
 &= p(x_*|\theta) p(\theta | D) \quad (\because (3.2)) \quad (3.5)
 \end{aligned}$$

→ (3.5) の  $\theta$  を積分消去

$$(左辺) = \int_{\theta} p(x_*, \theta | D) d\theta = p(x_* | D)$$

$$(右辺) = \int_{\theta} p(x_* | \theta) p(\theta | D) d\theta$$

∴ (3.3) が得る。

★ 予測分布  
事後分布が重心  
が変換を積分消去  
(左辺)  
⇒ 事前知識  $p(\theta)$  を削除。

まとめ

(3.4) で表すモデル

$$p(D, x_*, \theta) = p(D|\theta) p(x_*|\theta) p(\theta)$$

を用いて  $x_*$  を予測する。

1. (3.2)

$$p(\theta|D) = \frac{p(D|\theta) p(\theta)}{p(D)}$$

を用いて  $\pi^{\theta}$  を事後分布を求める。

2.  $\pi^{\theta}$  の自体は確定的。得られた事後分布が (3.3)

$$p(x_*|D) = \int p(x_*|\theta) p(\theta|D) d\theta$$

を用いて予測分布を算出する。 $x_*$  は肉眼事後分布を用いる。

①  $\pi^{\theta}$  の情報をすべて事後分布  $p(\theta|D)$  に反映させる。

△  $\pi^{\theta}$  の量は肉眼モデルの表現能力が変化しない。

(参考)

$\pi^{\theta}$  の合併せた予測モデルの表現能力を変えていく

と宣言モデル

◦ ガウス過程

◦ ベイジアニストのモデル

### 3.1.3 共役事前分布

#### 共役事前分布 (conjugate prior)

• (3.2)

$$p(\theta | D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$

における事前分布  $p(\theta)$  と事後分布  $p(\theta | D)$  が同じ種類の確率分布をもつように設定された事前分布。

• どうよくな事前分布が共役(?)かは、大変複雑  $p(D|\theta)$  の設計の仕方に依存。

• 参考文献で Chapter 3, p.p. 75, 76 を参照。

•  $\text{Beta} - \text{Beta}$  を 2つの分布 (e.g. ガウス分布) では、  
 $\text{Gamma} - \text{Gamma}$  を 實現させたりするよな共役事前分布が  
 ある。

~ 各確率分布と共に対応する共役分布を使い、  
 $\text{Beta-X} - \text{Beta}$  事後分布や予測分布の計算を確認。  
 (7.8c などがある本、中心 7-2)

③ 共役事前分布を使うことで  $\times 1$  トト。

◦ 事後分布や予測分布の計算が簡単にできるので (2)  
 実行できる。

… 適応宇宙 7L-47-1 の構成。

$\text{Beta} - \text{Beta}$  トト  $D_1$  を観測したあと、事後分布。

$$p(\theta | D_1) \propto p(D_1 | \theta) p(\theta) \quad (3.7)$$

新規  $\text{Beta} - \text{Beta}$  トト  $D_2$  を観測後。

$$p(\theta | D_1, D_2) \propto p(D_2 | \theta) p(\theta | D_1) \quad (3.8)$$

~ 共役事前分布を使うと、 $p(\theta)$ ,  $p(\theta | D_1)$ ,  $p(\theta | D_1, D_2)$  はすべて同じ形式。

- 解析的又は事後分布の計算ができない複数のモデル  
 ... 山伏人手汚を用いた事後分布の計算  
 ~) 共役分布を組み合せて全体のモデル構築 (7.11.12)  
 計算効率が高いためアルゴリズムを考へる。

### 3.1.4. 共役でない事前分布の利用。

(特徴)

データによる興味深い構造を捉えづら、共役でない事前分布を採用する。

(例) ガウス分布の平均  $\mu$

事前分布：ガウス分布（共役でない）

方法：MCMC, 変分推論

事後分布  $p(\theta | D)$  を変分  $p(\theta | \eta)$   
 を使つて、 $f_2$  以下の形の分布  $q(\theta; \eta)$  で  
 山伏人の表現で表すと仮定。  
 $\rightarrow$  フルタリング - ニューラルネット。

$$\eta_{\text{opt}} = \arg \min_{\eta} KL[q(\theta; \eta) || p(\theta | D)]$$

勾配法

(3.9)

3.2. 離散確率分布の学習と予測.

3.2.1. ベルヌイ分布の予測と予測.

$$x \in \{0, 1\}$$

$$p(x|\mu) = \text{Bern}(x|\mu) \quad (= \mu^x (1-\mu)^{1-x}) \quad (3.10)$$

⇒  $\mu$  の分布を訓練データから推論.

③ ベルヌイ予測, 参考方.

不確実性を持つ個体可へる確率変数の取扱い,  
確率分布を事前に設定する必要がある.

⇒  $\mu \in (0, 1)$  を生成する確率分布(ベルヌイ分布)を用意.

$$p(\mu) = \text{Beta}(\mu|a, b) \quad (= \underbrace{\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}}_{C_B(a,b)} \mu^{a-1} (1-\mu)^{b-1}) \quad (3.11)$$

$$a, b: 11111^\circ - 1^\circ \rightarrow \text{正}$$

... given

→ i.i.d. assumption?

⇒  $X = \{x_1, \dots, x_n\}$  を観測 LT2 後の事後分布を求める.

$$p(\mu|X) \propto p(X|\mu) p(\mu)$$

$$\propto \prod_{i=1}^n p(x_i|\mu) p(\mu) \quad (3.12)$$

(3.12) 1 = 累積確率  $\Sigma x_i$  (指數分布の導出)

$$\begin{aligned}
 \ln p(\mu | \mathbf{x}) &= \ln \left[ \prod_{i=1}^N p(x_i | \mu) p(\mu) \right] + \text{const.} \\
 &= \sum_{i=1}^N \ln p(x_i | \mu) + \ln p(\mu) + \text{const.} \\
 &= \sum_{i=1}^N \ln \left[ \mu^{x_i} (1-\mu)^{1-x_i} \right] \\
 &\quad + \ln \left[ \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu^{a-1} (1-\mu)^{b-1} \right] + \text{const.} \\
 &= \sum_{i=1}^N x_i \ln \mu + \sum_{i=1}^N (1-x_i) \ln (1-\mu) \\
 &\quad + (a-1) \ln \mu + (b-1) \ln (1-\mu) + \text{const.} \\
 &= \left( \sum_{i=1}^N x_i + a-1 \right) \ln \mu \\
 &\quad + \left( N - \sum_{i=1}^N x_i + b-1 \right) \ln (1-\mu) + \text{const.}
 \end{aligned}$$

(3.13)

従って (2.43)

$$\ln \text{Beta}(\mu | \hat{a}, \hat{b}) = (\hat{a}-1) \ln \mu + (\hat{b}-1) \ln (1-\mu) + \ln C_a(\hat{a}, \hat{b})$$

従って  $\hat{a}$  と  $\hat{b}$  は、事後分布は  $\text{Beta}(a, b)$  分布で表される  
ことが分かる。

$$p(\mu | \mathbf{x}) = \text{Beta}(\mu | \hat{a}, \hat{b}) \quad (3.14)$$

$$\text{where } \hat{a} = \boxed{\sum_{i=1}^N x_i} + a \quad \text{ $x = 1$  の回数}$$

$$\hat{b} = N - \sum_{i=1}^N x_i + b \quad (3.15)$$

$x = 0$  の回数

Q) ベータ分布はいままでに何回コアニア博士が出て来た  
記憶を取扱う。

## (参考) 程馬食ベイ入法

- ベイ入字留における  $110^\circ \text{ラメータ}$  の実測値
- 事後分布を求める式  
～事後分布がベータ分布である +  $110^\circ \text{ラメータ}$  の値を明記する
- 事前分布が  $110^\circ \text{ラメータ} = 0$ 、りを適切更新(7.8)
- 事前分布が  $110^\circ \text{ラメータ} = 0$  ではある。

## c.f. 程馬食ベイ入法

$110^\circ - 110^\circ \text{ラメータ}$  を観測するまでに合わせて直角範囲、  
確率範囲は常に等かなる手法ではある。

- ① ベイ入字留の構成について、事前分布が  $110^\circ - 110^\circ \text{ラメータ}$ 。  
“(由)故に肉可とメイニ知識”を反映して上記、固定値とし  
設定された?

～もし  $110^\circ - 110^\circ \text{ラメータ}$  もデータから算出せらるる場合。  
 $110^\circ - 110^\circ \text{ラメータ}$  に対する式で事前分布を用意する。

### $110^\circ - 110^\circ \text{ラメータ}$ 設定?

- どんな事前分布、設定をしたとしても、データ収入が含まれると  
対応する事前分布は不等(?)一致する。
- 証拠となるデータが少ないとまでは見えず、予測者は  
自身の持つ信念(事前分布)に大きく影響する。
- $\Rightarrow$  データ収入が増えると、予測が、意見が大きく一致する。

未観測の値  $x_* \in [0, 1]$  の確率分布の計算.

$$p(x_*) = \int \underbrace{p(x_* | \mu) p(\mu)}_{p(x_*, \mu)} d\mu$$

(3.16)

$$= \int \text{Bern}(x_* | \mu) \text{Beta}(\mu | a, b) d\mu$$

$$= \int \mu^{x_*} (1-\mu)^{1-x_*} C_B(a, b) \mu^{a-1} (1-\mu)^{b-1} d\mu$$

$$= C_B(a, b) \int \mu^{x_* + a - 1} (1-\mu)^{(-x_* + b) - 1} d\mu$$

$\stackrel{\text{Beta}}{=} \text{Beta}(\mu | \bar{a}, \bar{b}) = C_B(\bar{a}, \bar{b}) \mu^{\bar{a}-1} (1-\mu)^{\bar{b}-1}$

(3.17)  $\int \text{Beta}(\mu | \bar{a}, \bar{b}) d\mu = 1$

より、(3.16) (3.17).

$$\begin{cases} \bar{a} = x_* + a \\ \bar{b} = 1 - x_* + b \end{cases}$$

$x_* < \epsilon,$

$$p(x_*) = \frac{C_B(a, b)}{C_B(\bar{a}, \bar{b})} \int C_B(\bar{a}, \bar{b}) \mu^{\bar{a}-1} (1-\mu)^{\bar{b}-1} d\mu$$

$$= \frac{C_B(a, b)}{C_B(x_* + a, 1 - x_* + b)}$$

$$= \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \cdot \frac{\Gamma(x_* + a)\Gamma(1 - x_* + b)}{\Gamma(x_* + a + 1)} \quad (3.18)$$

5.7.

$$p(x_* = 1) = \frac{\Gamma(a+b)}{\Gamma(a)\cancel{\Gamma(b)}} \cdot \frac{\Gamma(a+1)\cancel{\Gamma(b)}}{\Gamma(a+b+1)}$$

$\star \Gamma(x+1) = x\Gamma(x)$

$$= \frac{\Gamma(a+b) \cdot a \Gamma(a)}{\Gamma(a)(a+b) \Gamma(a+b)} = \frac{a}{a+b} \quad (3.19)$$

$$p(x_* = 0) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \cdot \frac{\cancel{\Gamma(a)}\Gamma(1+b)}{\Gamma(a+b+1)} \\ = \frac{\Gamma(a+b)}{\Gamma(b)(a+b)\Gamma(a+b)} \cdot \frac{b}{a+b} \quad (3.20)$$

次に

$$p(x_*) = \left(\frac{a}{a+b}\right)^{x_*} \left(\frac{b}{a+b}\right)^{1-x_*} \\ = \left(\frac{a}{a+b}\right)^{x_*} \left(1 - \frac{a}{a+b}\right)^{1-x_*} \\ = \text{Bern}\left(x_* \mid \frac{a}{a+b}\right) \quad (3.21)$$

④ これより、 $p(\mu | X)$  が「ベータ分布」の形をとる。

$$p(x_* | X) = \text{Bern}\left(x_* \mid \frac{\hat{a}}{\hat{a} + \hat{b}}\right) \\ = \text{Bern}\left(x_* \mid \frac{\sum_{i=1}^N x_i + a}{N + a + b}\right) \quad (3.22)$$

3.2.2. カテゴリ分布, 等質と予測.

$$p(\mathbf{s} | \boldsymbol{\pi}) = \text{Cat}(\mathbf{s} | \boldsymbol{\pi}) \left( = \prod_{k=1}^K \pi_k^{s_k} \right) \quad (3.23)$$

$$\text{where } \sum_{k=1}^K \pi_k = 1, \quad \pi_k \in (0, 1)$$

~  $\boldsymbol{\pi}$  を生成する分布は ディリゲント分布.

$$p(\boldsymbol{\pi}) = \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\alpha}) = \frac{C_p(\boldsymbol{\alpha})}{\prod_{k=1}^K \pi_k^{\alpha_k - 1}} \frac{\prod_{k=1}^K \pi_k^{\alpha_k - 1}}{\Gamma(\sum_{k=1}^K \alpha_k)} \quad (3.24)$$

~ ディリゲント分布がカテゴリ分布 (= 独立共役事前分布) である  
= エピレギュラ子.

$$\mathbf{T}^{-1} = \mathbf{S} = \{ \mathbf{s}_1, \dots, \mathbf{s}_n \} \quad \cdots \text{離散値}$$

$$\begin{aligned} p(\boldsymbol{\pi} | \mathbf{S}) &\propto p(\mathbf{S} | \boldsymbol{\pi}) p(\boldsymbol{\pi}) \quad (\because \text{Bayes}) \\ &= \left( \prod_{i=1}^n \text{Cat}(\mathbf{s}_i | \boldsymbol{\pi}) \right) \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\alpha}) \quad (3.25) \end{aligned}$$

対数式と.

$$\begin{aligned} \ln p(\boldsymbol{\pi} | \mathbf{S}) &= \sum_{i=1}^n \ln \text{Cat}(\mathbf{s}_i | \boldsymbol{\pi}) + \ln \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\alpha}) + \text{const.} \\ &= \sum_{i=1}^n \ln \left( \prod_{k=1}^K \pi_k^{s_{i,k}} \right) + \ln \left( C_p(\boldsymbol{\alpha}) \prod_{k=1}^K \pi_k^{\alpha_k - 1} \right) \\ &= \sum_{i=1}^n \sum_{k=1}^K s_{i,k} \ln \pi_k + \sum_{k=1}^K (\alpha_k - 1) \ln \pi_k + \text{const.} \\ &= \sum_{k=1}^K \ln \pi_k \left( \sum_{i=1}^n s_{i,k} + \alpha_k - 1 \right) + \text{const.} \quad (3.26) \end{aligned}$$

事前分布  $(1/10 - 1/10)^{n-9/2}$   
二乗和の逆数

where  $s_{i,k} : \mathbf{s}_i$  の  $k$  番目要素.

∴  $\pi$  が  $\text{Dir}(\pi | \alpha)$  の p.d.f. である.

$$\ln \left( C_p(\hat{\alpha}) \prod_{k=1}^K \pi_k^{\hat{\alpha}_k - 1} \right) = \sum_{k=1}^K (\hat{\alpha}_k - 1) \ln \pi_k + \text{const.}$$

よし.

$$p(\pi | \Sigma) = \text{Dir}(\pi | \hat{\alpha}) \quad (3.27)$$

where  $\hat{\alpha} = (\hat{\alpha}_1, \dots, \hat{\alpha}_K)$ ,

$$\hat{\alpha}_k = \sum_{i=1}^N S_{i,k} + \alpha_k, \quad \text{for } k = 1, \dots, K \quad (3.28)$$

… 事後分布も  $\text{Dir}(\pi | \Sigma)$  分布は 2 つ.

2 種類、予測分布の計算を行おう

… 未観測  $S_*$  を  $(1, 1, \dots, 1)^T$  とすると  $\pi$  を予測する事前分布  $p(\pi)$   
に基づいて予測.

$\sim \pi$  を周辺化.  $p(\Sigma_* | \pi)$

$$\begin{aligned} p(\Sigma_*) &= \int \underbrace{p(\Sigma_* | \pi)}_{p(\Sigma_* | \pi)} p(\pi) d\pi \\ &= \int C_p(\alpha) \text{Dir}(\pi | \alpha) d\pi \\ &= \int \prod_{k=1}^K \pi_k^{S_{*,k}} C_p(\alpha) \prod_{k=1}^K \pi_k^{\alpha_k - 1} d\pi \\ &= C_p(\alpha) \int \prod_{k=1}^K \pi_k^{S_{*,k} + \alpha_k - 1} d\pi \end{aligned}$$

∴  $\pi$  が  $\text{Dir}(\pi | \bar{\alpha})$  の p.d.f. である.

$$\int \text{Dir}(\pi | \bar{\alpha}) d\pi = C_p(\bar{\alpha}) \int \prod_{k=1}^K \pi_k^{\bar{\alpha}_k - 1} d\pi = 1$$

よし.

$$\begin{aligned}
 p(S_* | \pi) &= \frac{C_P(\alpha)}{C_D(\bar{\alpha})} C_D(\bar{\alpha}) \int_{\sum_{k=1}^K \pi_k^{\bar{\alpha}_k - 1}} d\pi \\
 &= \frac{C_D(\alpha)}{C_D((S_{*,k} + \alpha_k)_{k=1}^K)} \quad (\bar{\alpha}_k = S_{*,k} + \alpha_k) \quad (3.29)
 \end{aligned}$$

where  $(S_{*,k} + \alpha_k)_{k=1}^K$  : K dim vector.

$$\begin{cases} \text{Def.} \\ C_D(\alpha) = \frac{T(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K T(\alpha_k)} \\ C_D((S_{*,k} + \alpha_k)_{k=1}^K) = \frac{T(\sum_{k=1}^K S_{*,k} + \alpha_k)}{\prod_{k=1}^K T(S_{*,k} + \alpha_k)} \end{cases}$$

5'.

$$p(S_* | \pi) = \frac{T(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K T(\alpha_k)} \cdot \frac{\prod_{k=1}^K T(S_{*,k} + \alpha_k)}{T(\sum_{k=1}^K S_{*,k} + \alpha_k)} \quad (3.30)$$

註記3.

注意到，若某個  $k'$  是選出來的， $S_{*,k'} = 1$  時機率會變小，

$$\begin{aligned}
 p(S_{*,k'} = 1) &= \frac{T(\sum_{k=1}^K \alpha_k), \prod_{k \neq k'} T(\alpha_k) T(1 + \alpha_{k'})}{\prod_{k=1}^K T(\alpha_k) T(\sum_{k=1}^K \alpha_k)} \\
 &= \frac{T(\sum_{k=1}^K \alpha_k)}{T(\alpha_{k'})}, \frac{\alpha_{k'} T(\alpha_{k'})}{\sum_{k=1}^K \alpha_k \cdot T(\sum_{k=1}^K \alpha_k)} \\
 &\approx \frac{\alpha_{k'}}{\sum_{k=1}^K \alpha_k} \quad (3.31)
 \end{aligned}$$

即，若要選出  $k'$  分布與  $\pi$  不同時機率會變小。

$$\begin{aligned}
 p(S_*) &= C_{\alpha_f} \left( S_* \mid \left( \frac{\alpha_{k'}}{\sum_{k=1}^K \alpha_k} \right)_{k=1}^K \right) \quad (3.32) \\
 - p(S_*(S)) \text{ if } \alpha \leftarrow \hat{\alpha} \text{ 由 } \pi \text{ 計算得。}
 \end{aligned}$$

### 3.2.3. ポアソン分布の学習と予測

④ ポアソン分布を使、尤事後分布と予測分布の計算。

$$p(x|\lambda) = P_{oi}(x|\lambda) \left( = \frac{\lambda^x}{x!} e^{-\lambda} \right) \quad (3.33)$$

where  $\lambda \in \mathbb{R}_+$ .

$\leadsto \lambda$  の事前分布は?

$$P(\lambda) = \text{Gam}(\lambda|a, b) \left( = \frac{C_G(a, b)}{\Gamma(a)} \lambda^{a-1} e^{-b\lambda} \right) \quad (3.34)$$

where  $a, b \in \mathbb{R}_+$  are fixed. (Hyper Parameter)

Given :  $X = \{x_1, \dots, x_N\} \sim \text{Poisson distribution}$

$$\Rightarrow p(\lambda|X) \propto p(X|\lambda) p(\lambda)$$

$$= \left( \prod_{i=1}^N Poi(x_i|\lambda) \right) \text{Gam}(\lambda|a, b) \quad (3.35)$$

$$\begin{aligned} \ln p(\lambda|X) &= \sum_{i=1}^N \ln \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} + \ln C_G(a, b) \lambda^{a-1} e^{-b\lambda} + \text{const.} \\ &= \sum_{i=1}^N (x_i \ln \lambda - \lambda - \ln x_i!) \\ &\quad + (a-1) \ln \lambda - b\lambda + \ln C_G(a, b) + \text{const.} \\ &= \left( \sum_{i=1}^N x_i + a-1 \right) \ln \lambda + (N-b)\lambda + \text{const.} \end{aligned} \quad (3.36)$$

よし、これは尤分布が対数と似た形だ。

$$p(\lambda | \mathbf{x}) = \text{Gam}(\lambda | \hat{a}, \hat{b}) \quad (3.37)$$

where  $\hat{a} = \sum_{i=1}^n x_i + a$ ,  $\hat{b} = N + b \quad (3.38)$

2次元、予測分布を求める。

事前分布:  $(3.34)$

$$p(\lambda) = \text{Gam}(\lambda | a, b)$$

~ 未観測  $\lambda -> x_*$  は実質予測分布は、

$$\begin{aligned} p(x_* | \lambda) &= \int p(x_* | \lambda) p(\lambda) d\lambda \\ &= \int \text{Poi}(x_* | \lambda) \text{Gam}(\lambda | a, b) d\lambda \quad (3.39) \\ &= \int \frac{\lambda^{x_*}}{x_*!} e^{-\lambda} C_G(a, b) \lambda^{a-1} e^{-b\lambda} d\lambda \\ &= \frac{C_G(a, b)}{x_*!} \int \lambda^{x_*+a-1} e^{-(1+b)\lambda} \quad (3.40) \end{aligned}$$

∴ ガンマ分布  $\text{Gam}(\lambda | \bar{a}, \bar{b}) = C_G(\bar{a}, \bar{b}) \lambda^{\bar{a}-1} e^{-\bar{b}\lambda}$   
 (= 実質)。

$$\int C_G(\bar{a}, \bar{b}) \lambda^{\bar{a}-1} e^{-\bar{b}\lambda} d\lambda = 1$$

∴

$$\begin{aligned} p(x_*) &= \frac{C_G(a, b)}{x_*! C_G(\bar{a}, \bar{b})} \int C_G(\bar{a}, \bar{b}) \lambda^{\bar{a}-1} e^{-\bar{b}\lambda} d\lambda \quad (\bar{a} = x_* + a, \bar{b} = 1 + b) \\ &= \frac{C_G(a, b)}{x_*! C_G(x_* + a, 1 + b)} \quad (3.42) \end{aligned}$$

~ 負二乗分布,  $\frac{b^a}{T(a)}, \frac{1}{x_*!}, \frac{T(x_* + a)}{(1+b)^{x_* + a}}$

Let  $r \in \mathbb{R}_+$ ,  $p \in (0, 1)$

$$\begin{aligned} p(x_*) &= N\beta(x_* | r, p) \\ &= \frac{T(x_* + r)}{x_*!T(r)} (1-p)^r p^{x_*} \quad (3.43) \end{aligned}$$

属于 P.d.f., 属于 Beta 分布且具有  $\alpha = r$  分布  $\beta = 1 - r$ .

$f = f_{\text{Beta}}$ .

$$\begin{cases} r = a \\ p = \frac{1}{b+1} \end{cases} \quad (3.44)$$

$$1 - \frac{1}{b+1} = \frac{b+1-1}{b+1} = \frac{b}{b+1}$$

所以

$$\langle x_* \rangle = \frac{pr}{(1-p)} \quad (3.45)$$

$$\begin{aligned} &\left(\frac{b}{b+1}\right)^a \cdot \left(\frac{1}{b+1}\right)^{x_*} \\ &= b^a (1+b)^{-a-x_*} \end{aligned}$$

$$\langle x_*^2 \rangle = \frac{pr(p+r+1)}{(1-p)^2} \quad (3.46)$$

所以