

## ベイズ本 4.3.2 節

ここでは、例として、ポアソン混合モデルの事後分布からパラメータと潜在変数をサンプルする．導出は手書きの資料に載せているので、ここでは省略する．

### ■Notation

以下の記号を用いる．

- $\mathbf{X} = \{x_1, \dots, x_N\}$ : データ
- $\boldsymbol{\lambda} = \{\lambda_1, \dots, \lambda_K\}$ : ポアソン分布のパラメータの集合
- $\mathbf{S} = \{\mathbf{s}_1, \dots, \mathbf{s}_N\}$ : 潜在変数の集合
  - $\mathbf{s}_n$ :  $k$  次元ベクトル
  - $s_{n,k} = 1 \iff k$  番目のクラスタが指定された
- $\boldsymbol{\pi}$ : 混合比率
  - $\sum_{k=1}^K \pi_k = 1$

### ■モデル

まず、以下の確率分布を定義する．

- クラスタ  $k$  に対する観測モデル:

$$p(x_n | \lambda_k) = \text{Poi}(x_n | \lambda_k), \quad k = 1, \dots, K. \quad (1)$$

- $\mathbf{s}_n$  をサンプルするための分布:

$$p(\mathbf{s}_n | \boldsymbol{\pi}) = \text{Cat}(\mathbf{s}_n | \boldsymbol{\pi}). \quad (2)$$

- 混合分布における条件付き分布:

$$p(x_n | \mathbf{s}_n, \boldsymbol{\lambda}) = \sum_{k=1}^K \text{Poi}(x_n | \lambda_k)^{s_{n,k}}. \quad (3)$$

- ポアソン分布のパラメータ  $\boldsymbol{\lambda}$  に対する事前分布:

$$p(\lambda_k) = \text{Gam}(\lambda_k | a, b), \quad k = 1, \dots, K. \quad (4)$$

- $a, b$ : ハイパーパラメータ.

- 混合比率  $\pi$  に対する事前分布:

$$p(\pi) = \text{Dir}(\pi|\alpha). \quad (5)$$

- $\alpha$ : ハイパーパラメータ.  $K$  次元ベクトル.

これらを用いると, 同時分布は

$$\begin{aligned} p(\mathbf{X}, \mathbf{S}, \boldsymbol{\lambda}, \pi) &= p(\mathbf{X}|\mathbf{S}, \boldsymbol{\lambda})p(\mathbf{S}|\pi)p(\boldsymbol{\lambda})p(\pi) \\ &= \left( \prod_{n=1}^N p(x_n|s_n, \boldsymbol{\lambda})p(s_n|\pi) \right) \left( \prod_{k=1}^K p(\lambda_k) \right) p(\pi) \end{aligned} \quad (6)$$

と表される [1].

### ■ギブスサンプリング

データ  $\mathbf{X}$  が観測されたあと, パラメータ  $\boldsymbol{\lambda}$ ,  $\pi$  と潜在変数  $\mathbf{S}$  をサンプルする. 潜在変数とパラメータを分けてサンプルすることを考えると,

$$\mathbf{S} \sim p(\mathbf{S}|\mathbf{X}, \boldsymbol{\lambda}, \pi) \quad (7)$$

$$\boldsymbol{\lambda}, \pi \sim p(\boldsymbol{\lambda}, \pi|\mathbf{X}, \mathbf{S}) \quad (8)$$

となる.

潜在変数  $\mathbf{S}$  について. 条件付き独立性が示され, 各  $s_n$  に対して,

$$s_n \sim \text{Cat}(s_n|\eta_n), \quad (9)$$

ただし,

$$\eta_{n,k} \propto \exp(x_n \ln \lambda_k - \lambda_k + \ln \pi_k), \quad \text{s.t.} \quad \sum_{k=1}^K \eta_{n,k} = 1 \quad (10)$$

である [1].

$\boldsymbol{\lambda}$ ,  $\pi$  について.  $\mathbf{X}$ ,  $\mathbf{S}$  が与えられた下では, 2つの分布が独立であることが示される.  $\boldsymbol{\lambda}$  の分布は, 各  $k$  に対して

$$\lambda_k \sim \text{Gam}(\lambda_k|\hat{a}_k, \hat{b}_k), \quad (11)$$

ただし,

$$\hat{a}_k = \sum_{n=1}^N s_{n,k} x_n + a \quad (12)$$

$$\hat{b}_k = \sum_{n=1}^N s_{n,k} + b \quad (13)$$

である [1].

また,  $\pi$  の分布は

$$\pi \sim \text{Dir}(\pi|\hat{\alpha}), \quad (14)$$

ただし,

$$\hat{\alpha}_k = \sum_{n=1}^N s_{n,k} + \alpha_k \quad (15)$$

である.

以上を用いると, ポアソン混合モデルの事後分布に対するギブスサンプリングは Algorithm 1 で与えられる.

---

**Algorithm 1** Gibbs Sampling for Poisson mixture model.

---

**Input:** MAXITER: the number of iteration,  $N$ : the number of data,  $K$ : the number of clusters.

**Output:**  $\mathcal{S}_{\text{sample}}, \lambda_{\text{sample}}, \pi_{\text{sample}}$ : The set of sampled parameters and the set of hidden variables.

*Initialisation :*

1:  $\mathcal{S}_{\text{sample}} \leftarrow \emptyset, \lambda_{\text{sample}} \leftarrow \emptyset, \pi_{\text{sample}} \leftarrow \emptyset$ . Set  $\lambda_{\text{init}}$  and  $\pi_{\text{init}}$ .

*LOOP Process*

2: **for**  $i = 1$  to MAXITER **do**

3:   **for**  $n = 1$  to  $N$  **do**

4:     Sample  $s_n$  using (9).

5:   **end for**

6:    $\mathcal{S}_i \leftarrow \{s_1, \dots, s_n\}, \mathcal{S}_{\text{sample}} \leftarrow \mathcal{S}_{\text{sample}} \cup \{\mathcal{S}_i\}$ .

7:   **for**  $k = 1$  to  $K$  **do**

8:     Sample  $\lambda_k$  using (11).

9:   **end for**

10:    $\lambda_i \leftarrow \{\lambda_1, \dots, \lambda_K\}, \lambda_{\text{sample}} \leftarrow \lambda_{\text{sample}} \cup \{\lambda_i\}$ .

11:   Sample  $\pi$  using (14).

12:    $\pi_i \leftarrow \pi, \pi_{\text{sample}} \leftarrow \pi_{\text{sample}} \cup \{\pi_i\}$ .

13: **end for**

14: **return**  $\mathcal{S}_{\text{sample}}, \lambda_{\text{sample}}, \pi_{\text{sample}}$

---

## 参考文献

[1] A. Suyama, ベイズ推論による機械学習 入門, 講談社, 2017.