

仮説集合の複雑度 2.1節

参考文献

- 金森, 統計的学習理論, 講談社, 2015.

Table of contents

- VC次元

VC次元

- VC dimension
 - Vapnik and Chervonenkis
 - 2値判別問題のための仮説集合に対して定義される複雑度
 - 多値判別や回帰問題の場合に拡張することも可能.
 - 集合族の組合せ的な性質を捉えるための量
 - 組合せ論などにも応用

- \mathcal{H} : 2値判別のための仮説集合
 - $h \in \mathcal{H}$: 仮説 ($h : \mathcal{X} \rightarrow \mathcal{Y}$, $|\mathcal{Y}| = 2$)

$\{x_1, \dots, x_n\} \subset \mathcal{X}$: 入力の集合 に対して, \mathcal{Y}^n の部分集合

$$\{(h(x_1), \dots, h(x_n)) \in \mathcal{Y}^n \mid h \in \mathcal{H}\}$$

の要素数を

$$\Pi_{\mathcal{H}}(x_1, \dots, x_n) = |\{(h(x_1), \dots, h(x_n)) \in \mathcal{Y}^n \mid h \in \mathcal{H}\}|$$

とおく. 定義から,

$$\Pi_{\mathcal{H}}(x_1, \dots, x_n) \leq 2^n$$

が成り立つ.

等式 $\Pi_{\mathcal{H}}(x_1, \dots, x_n) = 2^n$ が成り立つとする.

\rightsquigarrow 各 x_i にラベル $y_i \in \mathcal{Y}$ を割り付けて得られる任意の2値データ $\{(x_1, y_1), \dots, (x_n, y_n)\}$ に対して, 適切に $h \in \mathcal{H}$ を選べば

$$h(x_i) = y_i, \quad i = 1, \dots, n$$

とできる.

入力の数 n が増えていけば, ラベル付けのパターンが豊富になり, 上記の等式が成立しにくくなると考えられる.

その境界となるデータ数 n を \mathcal{H} の VC 次元という. つまり,

$$\text{VCdim}(\mathcal{H}) = \max \left\{ n \in \mathbb{N} \mid \max_{x_1, \dots, x_n \in \mathcal{X}} \Pi_{\mathcal{H}}(x_1, \dots, x_n) = 2^n \right\}$$

と定義される.

$$\text{VCdim}(\mathcal{H}) = \infty \stackrel{\text{def}}{\iff} \forall n \in \mathbb{N}, \exists x_1, \dots, x_n \in \mathcal{X}, \Pi_{\mathcal{H}}(x_1, \dots, x_n) = 2^n.$$

- VC次元の解釈
 - どのようなラベル付けにも対応可能な仮説が存在するようなデータ数の上限
- データ数 n が $n \leq \text{VCdim}(\mathcal{H})$ のときは学習がうまくいくと考えることもできる.
 - ノイズによってラベルが反転してしまう状況を考えると、必ずしも学習がうまくいくわけではない
 - 仮説集合がどのようなラベル付けにも対応できる = ノイズとして無視すべきデータも学習してしまう
 - 仮説集合の複雑度は、データの複雑さに合わせて適切に設定することが重要

Lemma 2.1 (Sauer's lemma)

2値ラベルに値をとる仮説集合 \mathcal{H} のVC次元が d のとき, $n \geq d$ に対して

$$\max_{x_1, \dots, x_n \in \mathcal{X}} \Pi_{\mathcal{H}}(x_1, \dots, x_n) \leq \left(\frac{en}{d}\right)^d \quad (e: \text{ネイピア数})$$

Th 2.2

2値ラベルに値をとる仮説集合 $\mathcal{H} \subset \{h: \mathcal{X} \rightarrow \{-1, +1\}\}$ のVC次元を $d < \infty$ とする. 学習データ $(X_1, Y_1), \dots, (X_n, Y_n)$ はi.i.d.であるとする. 損失として0-1損失を用いると, $n \geq d$ のとき, 学習データの分布の下で確率 $1 - \delta$ 以上で

$$\sup_{h \in \mathcal{H}} |R_{\text{err}}(h) - \hat{R}_{\text{err}}(h)| \leq 2\sqrt{\frac{2d}{n} \log \frac{en}{d}} + \sqrt{\frac{\log(2/\delta)}{2n}}$$

が成り立つ.

Lemma 2.1の証明は略． Th 2.2の証明は2.3節で示す．

Th 2.2を用いて，推定された仮説の予測判別誤差を評価する．

⇨ 有限集合ではない仮説集合が扱える．

- $S = \{(X_1, Y_1), \dots, (X_n, Y_n)\}$: 学習データ
- h_S : 経験判別誤差 $\hat{R}_{\text{err}}(h)$ の最小化によって得られる仮説
- h_0 : ベイズ規則
 - 予測損失 $R_{\text{err}}(h)$ の下限を達成する仮説
 - $h_0 \in \mathcal{H}$ を仮定．

⇨ 以下の不等式が常に成立

$$\hat{R}_{\text{err}}(h_S) \leq \hat{R}_{\text{err}}(h_0), \quad R_{\text{err}}(h_0) \leq R_{\text{err}}(h_S)$$

⇨ 学習データ S の分布の下で, $1 - \delta$ 以上の確率で以下が成立.

$$\begin{aligned} R_{\text{err}}(h_S) &\leq \hat{R}_{\text{err}}(h_0) + R_{\text{err}}(h_S) - \hat{R}_{\text{err}}(h_S) \quad (\because \hat{R}_{\text{err}}(h_0) \geq \hat{R}_{\text{err}}(h_S)) \\ &\leq R_{\text{err}}(h_0) + |R_{\text{err}}(h_0) - \hat{R}_{\text{err}}(h_0)| + \sup_{h \in \mathcal{H}} |R_{\text{err}}(h) - \hat{R}_{\text{err}}(h)| \quad (\because (\dagger), (\ddagger)) \\ &\leq R_{\text{err}}(h_0) + 2 \sup_{h \in \mathcal{H}} |R_{\text{err}}(h) - \hat{R}_{\text{err}}(h)| \quad (\because (\ddagger)) \\ &\leq R_{\text{err}}(h_0) + 4 \sqrt{\frac{2d}{n} \log \frac{en}{d}} + 2 \sqrt{\frac{\log(2/\delta)}{2n}} \quad (\because \text{Th 2.2}) \end{aligned}$$

これより,

$$R_{\text{err}}(h_0) \leq R_{\text{err}}(h_S) \leq R_{\text{err}}(h_0) + O_p \left(\sqrt{\frac{\log(n/d)}{n/d}} \right)$$

となる.

⇨ 予測判別誤差はデータ数とVC次元の比 n/d と関連している.

(†)

$$\begin{aligned}\hat{R}_{\text{err}}(h_0) &= R_{\text{err}}(h_0) - R_{\text{err}}(h_0) + \hat{R}_{\text{err}}(h_0) \\ &\leq R_{\text{err}}(h_0) + |R_{\text{err}}(h_0) - \hat{R}_{\text{err}}(h_0)|\end{aligned}$$

(‡)

$$\begin{aligned}R_{\text{err}}(h_S) - \hat{R}_{\text{err}}(h_S) &\leq |R_{\text{err}}(h_S) - \hat{R}_{\text{err}}(h_0)| \\ &\leq \sup_{h \in \mathcal{H}} |R_{\text{err}}(h) - \hat{R}_{\text{err}}(h)|\end{aligned}$$

以下，VC次元の例を示す．

例 2.1 (有限仮説集合)

有限な仮説集合 \mathcal{H} に対して

$$\text{VCdim}(\mathcal{H}) \leq \log_2 |\mathcal{H}|$$

が成り立つ.

- d 個の入力点に割り当てられるラベルのパターンは 2^d 通り
 - $|\mathcal{H}| < 2^d$ ならば, すべてのラベルの割り当てに対応することができない

⇨ 推定された仮説 h_S の予測損失について

$$R_{\text{err}}(h_0) \leq R_{\text{err}}(h_S) \leq R_{\text{err}}(h_0) + O_p \left(\sqrt{\frac{\log |\mathcal{H}|}{n}} \log \frac{n}{\log |\mathcal{H}|} \right)$$

が成立する.

例 2.2 (線形判別器のVC次元)

- $\mathcal{X} = \mathbb{R}^d$: 入力空間
- $\mathcal{H} = \{h(x) = \text{sign}(w^T x + b) \mid w \in \mathbb{R}^d, b \in \mathbb{R}\}$: 仮説集合 (線形判別器の集合)
- $\{x_1, \dots, x_{d+1}\} \subset \mathbb{R}^d$: 列ベクトルの集合

これらのベクトルが \mathbb{R}^d で一般の位置にあるとき

$$A = \begin{pmatrix} x_1 & \cdots & x_{d+1} \\ 1 & \cdots & 1 \end{pmatrix} \in \mathbb{R}^{(d+1) \times (d+1)}$$

は可逆な行列となる.

入力 x_i にラベル $y_i \in \{+1, -1\}$ を割り当てたデータに対して

$$\begin{pmatrix} w \\ b \end{pmatrix} = A^{-1} y, \quad y = (y_1, \dots, y_{d+1})^T$$

とすれば, $h(x_i) = y_i, i = 1, \dots, n$ が成立.

実際,

$$y = A \begin{pmatrix} w \\ b \end{pmatrix} = (w^T x_1 + b, \dots, w^T x_{d+1} + b)^T$$

より, $y_i = w^T x_i + b = \text{sign}(w^T x_i + b)$ となる.

$$\rightsquigarrow \text{VCdim}(\mathcal{H}) \geq d + 1$$

以下, VC 次元の上界を求めるのに役立つラドンの定理を紹介する.

集合 A の凸包 $\text{conv}(A)$ を

$$\text{conv}(A) = \left\{ \sum_{i=1}^n \alpha_i x_i \mid n \in \mathbb{N}, \sum_{i=1}^n \alpha_i = 1, \alpha_i \in [0, 1], x_i \in A \right\}$$

とする.

Th 2.3 (ラドンの定理)

任意の点集合 $S = \{x_1, \dots, x_{d+2}\} \subset \mathbb{R}^d$ に対して, $S = S_1 \cup S_2$, $S_1 \cap S_2 = \emptyset$ かつ $\text{conv}(S_1) \cap \text{conv}(S_2) \neq \emptyset$ となるような S の分割 S_1, S_2 が存在する.

- S_1, S_2
 - 任意の点集合 $\{x_1, \dots, x_{d+2}\} \subset \mathbb{R}^d$ に対して, ラドンの定理から定まる分割
- $y = +1$: S_1 の点である
- $y = -1$: S_2 の点である

このラベル付けに正答する線形判別器 $h \in \mathcal{H}$ が存在すると仮定する.

\rightsquigarrow h は $\text{conv}(S_1)$ の点に $+1$ を割り当て, $\text{conv}(S_2)$ の点に -1 を割り当てる.

$\rightsquigarrow S_1 \cap S_2$ で矛盾 \Rightarrow そのようなラベル付けは存在しない

$\rightsquigarrow \text{VCdim}(\mathcal{H}) = d + 1$

例 2.3

線形判別器の集合では，判別器を指定するパラメータの次元とVC次元が一致していた．しかし，常にパラメータの次元とVC次元が一致するわけではない．

- θ : 1次元パラメータ
- $\mathcal{H} = \{h(x) = \text{sign}(\sin(2\pi\theta x)) \mid \theta \in \mathbb{R}\}$: 仮説集合

$\rightsquigarrow \text{VCdim}(\mathcal{H}) = \infty$

\rightsquigarrow 適切に入力点を選べば，その上の任意のラベル付けに対応できる仮説が \mathcal{H} の中に存在する．