

カーネル法の基礎 4.4節

参考文献

- 金森, 統計的学習理論, 講談社, 2015.

Table of contents

- 表現定理

線形モデル $\mathcal{M} = \{f(x) = \beta^T \phi(x) \mid \beta \in \mathbb{R}^D\}$ における推定量 $\hat{f}(x)$

$$\hat{f}(x) = \sum_{i=1}^n \hat{\alpha}_i k(x_i, x)$$

- $\hat{\alpha} = (K + \lambda I_n)^{-1} Y$
- $k(x_i, \cdot)$, $i = 1, \dots, n$: データ点 x_i に対応するカーネル関数

⇨ カーネル関数の線形結合

⇨ この性質は、一般のRKHSにおいて表現定理としてまとめられる。

- \mathcal{X} : 入力空間
- $(\mathcal{H}, \langle \cdot, \cdot \rangle_{\mathcal{H}})$: \mathcal{X} 上のRKHS
 - k : 対応する再生核
- $\mathcal{H} + \mathbb{R} = \{f + b \mid f \in \mathcal{H}, b \in \mathbb{R}\}$: \mathcal{H} から構成される統計モデル

\rightsquigarrow データ $D = \{(x_1, y_1), \dots, (x_n, y_n)\}$ が与えられた下で以下の関数を最小化.

$$\min_{f, b} L(f(x_1) + b, \dots, f(x_n) + b; D) + \lambda \|f\|_{\mathcal{H}}^2 \quad (\lambda \geq 0) \quad (4.7)$$

\mathcal{H} の部分空間で,

- $S = \text{Span}\{k(x_1, \cdot), \dots, k(x_n, \cdot)\} \subset \mathcal{H}$
- $S^{\perp} = \{v \in \mathcal{H} \mid \langle v, w \rangle_{\mathcal{H}} = 0 \ \forall w \in S\}$: S の直交補空間

を考える.

$\rightsquigarrow f \in \mathcal{H}$ は,

$$f = f_S + f_{S^\perp} \quad (f_S \in S, f_{S^\perp} \in S^\perp)$$

と一意に分解できる (\because 射影定理).

部分空間 S の定義から,

$$\langle f, k(x_i, \cdot) \rangle = \langle f_S, k(x_i, \cdot) \rangle, \quad \|f\|_{\mathcal{H}}^2 = \|f_S\|_{\mathcal{H}}^2 + \|f_{S^\perp}\|_{\mathcal{H}}^2$$

が成り立つ.

$\rightsquigarrow f$ を f_S に変えると, 関数値は $\lambda \|f_{S^\perp}\|^2$ だけ減少する

$\rightsquigarrow f$ の最適解が存在する範囲として, 部分空間 S を考えれば十分.

以上の結果は, 表現定理としてまとめられる.

Th 4.10 (表現定理)

学習データを

$$D = \{(x_1, y_1), \dots, (x_n, y_n)\}$$

として, 関数

$$L(f(x_1) + b, \dots, f(x_n) + b; D) + \Psi(\|f\|_{\mathcal{H}}^2) \quad (4.8)$$

を $f \in \mathcal{H}$ と $b \in \mathbb{R}$ に関して最小化することを考える.

- L : 任意の関数, Ψ : 単調非減少関数

$\rightsquigarrow f \in \mathcal{H}$ について,

$$f(x) = \sum_{i=1}^n \alpha_i k(x_i, x) \quad (4.9)$$

と表せる最適解が存在する.

(4.8)による定式化

- 最適化すべきパラメータ f の次元が無限次元になることもありえる

表現定理

- $n + 1$ 次元パラメータ $(\alpha_1, \dots, \alpha_n, b)$ の最適化問題として定式化
- カーネル関数 $k(x, x')$ の値が簡単に計算できるなら、最適化の計算コストはデータ数 n によって決まる.

(4.8)の最適化を有限次元の問題として表す.

- $k_i := (k(x_i, x_1), \dots, k(x_i, x_n))^T \in \mathbb{R}^n$
- $K = (k_1, \dots, k_n)$: グラム行列
- $\alpha := (\alpha_1, \dots, \alpha_n)^T \in \mathbb{R}^n$

⇨ 関数(4.8)は

$$L(\alpha^T k_1 + b, \dots, \alpha^T k_n + b; D) + \Psi(\alpha^T K \alpha)$$

となる.

パラメータ α, b について最適化し, 最適解 $\hat{\alpha}, \hat{b}$ が得られたとき, 学習された関数は,

$$f(x) = \sum_{i=1}^n \hat{\alpha}_i k(x_i, x) + \hat{b}$$

と表される.