

# カーネル法の基礎 4.5 - 4.6節

## 参考文献

- 金森, 統計的学習理論, 講談社, 2015.

## Table of contents

- RKHSのラデマツハ複雑度
- 普遍カーネル

# RKHSのラデマツハ複雑度

Th 4.11

$\mathcal{X}$ 上の再生核Hilbert空間を $(\mathcal{H}, \langle \cdot, \cdot \rangle_{\mathcal{H}})$ とし，対応する再生核を $k : \mathcal{X}^2 \rightarrow \mathbb{R}$ とする．関数集合 $\mathcal{G} \subset \mathcal{H}$ は，

$$\mathcal{G} \subset \{f \in \mathcal{H} \mid \|f\|_{\mathcal{H}} \leq a\} \quad (a > 0)$$

を満たすとする．このとき，入力点の集合 $S = \{x_1, \dots, x_m\} \subset \mathcal{X}$ に対して経験ラデマツハ複雑度は，

$$\hat{\mathfrak{R}}_S(\mathcal{G}) \leq \frac{a}{m} \left( \sum_{i=1}^m k(x_i, x_i) \right)^{1/2}$$

となる．

(証明略)

カーネル関数が有界ならば，さらに次の不等式が得られる．

### Corollary 4.12

Th 4.11の条件に加えて，カーネル関数が $\sup_{x \in \mathcal{X}} k(x, x) \leq \Lambda^2$ を満たすとき，

$$\hat{\mathfrak{R}}_S(\mathcal{G}) \leq \frac{a\Lambda}{\sqrt{m}}$$

が成り立つ．

同様にして，入力の分布に関して期待値をとったラデマツハ複雑度 $\mathfrak{R}_m(\mathcal{G}) = \mathbb{E}_S[\hat{\mathfrak{R}}_S(\mathcal{G})]$ に対して，

$$\mathfrak{R}_m(\mathcal{G}) \leq \frac{a\sqrt{\mathbb{E}[k(x, x)]}}{\sqrt{m}} \leq \frac{a\Lambda}{\sqrt{m}}$$

が成り立つ．

# 普遍カーネル

## Def 4.13 普遍カーネル

- $\mathcal{X}$ : コンパクト距離空間,  $C(\mathcal{X})$ :  $\mathcal{X}$ 上の連続関数の集合
- $k$ :  $\mathcal{X}$ 上の連続なカーネル関数,  $\mathcal{H}$ :  $k$ に対応するRKHS  
任意の  $g \in C(\mathcal{X})$  と  $\varepsilon > 0$  に対して,  $f \in \mathcal{H}$  が存在して

$$\|f - g\|_{\infty} := \sup_{x \in \mathcal{X}} |f(x) - g(x)| \leq \varepsilon$$

となるとき,  $k$  を普遍カーネルという.

## Remark

- 普遍カーネルはコンパクト集合上で連続  $\rightsquigarrow$  有界
  - 対応する再生核Hilbert空間の元は連続関数からなる (from Th 4.7)

$$\rightsquigarrow \mathcal{H} \subset C(\mathcal{X})$$

## 普遍カーネルの例

$\mathbb{R}^d$  のコンパクト集合  $\mathcal{X}$  上の普遍カーネルの代表例

- ガウシアンカーネル
- 指数カーネル

$$k(x, x') = e^{x^{\mathrm{T}} x'}, \quad x, x' \in \mathcal{X}$$

- 2項カーネル

$$k(x, x') = (1 - x^{\mathrm{T}} x')^{-\alpha}, \quad x, x' \in \mathcal{X} \subset \{x \in \mathbb{R}^d \mid \|x\| < 1\}, \quad \alpha > 0$$

### Remark

- 多項式カーネルに対応するRKHSは有限次元なので、 $\mathcal{X} = \infty$  のときは普遍カーネルではない。

普遍カーネルから生成されるRKHSを用いれば，連続関数をよく近似できる (一般の可測関数の近似は保証されていない).

一方で，ベイズ誤差

$$R_{\text{err}}^* = \inf_{f:\text{可測}} \mathbb{E}[\mathbf{1}[\text{sign}(f(X)) \neq Y]]$$

は可測関数の集合上の下限で定義される.

$\rightsquigarrow$  RKHS  $\mathcal{H}$  上での予測判別誤差の下限が  $R_{\text{err}}^*$  に一致するなら， $\mathcal{H}$  の要素で十分精度が高い判別が可能.

一般の予測損失について、可測関数集合上の下限とRKHS上の下限の関係について考察する.

$f_1, \dots, f_L$ :  $\mathcal{X}$ 上の可測関数の組 が与えられたとき、データ  $(x, y) \in \mathcal{X} \times \mathcal{Y}$  に対する損失を考える.

判別問題を想定し、 $\mathcal{Y}$ を有限集合とする.

$L$ : 一般の自然数(2値判別では、 $L = 1$ , 多値判別では  $L = |\mathcal{Y}|$ ).

#### Th 4.14

- $\mathcal{H}$ :  $\mathcal{X}$ 上の普遍カーネルから定義されるRKHS
- $\mathcal{Y}$ : 有限集合

非負値をとる関数  $\ell : \mathbb{R}^L \times \mathcal{Y} \rightarrow \mathbb{R}_+$  に対して次の条件を仮定.

1. 任意の  $y \in \mathcal{Y}$  に対して  $t \mapsto \ell(t, y)$  は  $\mathbb{R}^L$  上で連続.
2. 単調非減少関数  $h : \mathbb{R}_+ \rightarrow \mathbb{R}_+$  が存在し, 任意の  $(t, y) \in \mathbb{R}^L \times \mathcal{Y}$  に対して  $\ell(t, y) \leq h(\|t\|_1)$  が成立. ( $\|t\|_1$  は  $t \in \mathbb{R}^L$  の1-ノルム)

このとき,  $\mathcal{X} \times \mathcal{Y}$ 上の任意の確率分布に対して

$$\begin{aligned} & \inf_{f_1, \dots, f_L: \text{可測}} \mathbb{E}[\ell(f_1(X), \dots, f_L(X), Y)] \\ &= \inf_{f_1, \dots, f_L \in \mathcal{H}} \mathbb{E}[\ell(f_1(X), \dots, f_L(X), Y)] \end{aligned}$$

が成り立つ.