

# サポートベクトルマシン 5.1 - 5.2節

## 参考文献

- 金森, 統計的学習理論, 講談社, 2015.

## Table of contents

- 導入
- ヒンジ損失

## 導入

- $C$ -サポートベクトルマシン
  - データ数に応じて適切に $C$ を調整することで、統計的一致性が達成される.
- $\nu$ -サポートベクトルマシン
  - ベイズ誤差を達成するためにはデータの分布の情報を用いて $\nu$ を調整する必要がある.
    - 実用面 + 理論的な観点で交差確認法などによるパラメータ調整が必要.

$C, \nu$ は正則化パラメータ.

⇨ これらを適切に調整すれば、これらの学習アルゴリズムは同じ学習データに対して同じ判別器を返す.

## 問題設定

Train data  $(x_1, y_1), \dots, (x_n, y_n) \in \mathcal{X} \times \{+1, -1\}$ : test data と同一分布, 独立  
目標

入力ベクトルと2値ラベルの間の関係をデータから学習し, 予測精度の高い判別器を得ること.

- $\mathcal{G} = \{f + b \mid f \in \mathcal{H}, b \in \mathbb{R}\}$ : 判別関数の集合
- $(\mathcal{H}, \langle \cdot, \cdot \rangle_{\mathcal{H}})$ :  $\mathcal{X}$  上の RKHS
- $\|\cdot\|_{\mathcal{H}}$ :  $\mathcal{H}$  のノルム
- $k(x, x')$ : 対応するカーネル関数
- $\text{sign} \circ \mathcal{G} = \{x \mapsto \text{sign}(g(x)) \mid g \in \mathcal{G}\}$ : 対応する判別器の集合 (仮説集合)

# ヒンジ損失

$$\phi_{\text{hinge}}(m) = \max\{1 - m, 0\}$$

から定義されるマージン損失

## ヒンジ損失の特徴付け

学習データ  $(x_i, y_i)$  に対して,  $f(x_i) + b$  の符号が  $y_i$  と同じなら,  $\text{sign}(f(x_i) + b)$  によって  $y_i$  を正しく判別できる

⇨ できるだけ多くの学習データに対して,  $y_i(f(x_i) + b) > 0$  が成立すれば, 学習データに適合しているという意味で望ましい判別器が得られる

⇨ 0-1マージン損失  $\phi_{\text{err}}(m)$  から定義される経験損失を最小化することで実現される

$\phi_{\text{err}}(m) = \mathbf{1}[m \leq 0]$  は凸関数ではないので, 最小化は一般に困難

⇨ 0-1マージンの代わりに凸関数から定義されるマージン損失を用いることで, 計算の困難を回避する

凸マージン損失 $\phi(m)$ が、 $\phi'(0) < 0$ を満たすとき、判別適合的な損失になる。

⇨ 損失を最小化して得られる判別器は、判別関数の統計モデルが十分大きいなら、ベイズ誤差に近い予測判別誤差を達成することが期待される。

### Proposition 5.1

凸関数 $\phi : \mathbb{R} \rightarrow \mathbb{R}$ は原点で微分可能で、 $\phi'(0) = -1$ を満たすとする。また、 $\rho > 0$ として、任意の $m \in \mathbb{R}$ に対して $\rho \cdot \mathbf{1}[m \leq 0] \leq \phi(m)$ が成り立つとする。このとき、 $\forall m \in \mathbb{R}$ に対して

$$\rho \cdot \mathbf{1}[m \leq 0] \leq \max\{\rho - m, 0\} \leq \phi(m)$$

が成り立つ。

$C$ -サポートベクトルマシンでは $\rho = 1$ とした通常のヒンジ損失を用いる。 $\nu$ -サポートベクトルマシンでは $\rho$ を可変パラメータとして扱う。